

华北电力大学

专业硕士学位论文

基于网络二手书平台的定价机理研究

Research on Pricing Mechanism Based on Network Second-hand Book Platform

李荣杰

2024年6月

国内图书分类号: O212.1
国际图书分类号: 519.2

学校代码: 10079
密 级: 公开

专业硕士学位论文

基于网络二手书平台的定价机理研究

硕 士 研 究 生: 李荣杰

导 师: 叶振军副教授

企 业 导 师: 王瑞阳

申 请 学 位: 应用统计专业硕士

专 业 领 域: 应用统计

学 习 方 式: 全日制

所 在 学 院: 数理学院

答 辩 日 期: 2024 年 6 月

授予学位单位: 华北电力大学

Classified Index: O212.1
U.D.C: 519.2

Thesis for the Professional Master's Degree

Research on Pricing Mechanism Based on Network Second-hand Book Platform

Candidate:	Li Rongjie
Supervisor:	Ye Zhenjun
Enterprise mentor:	Wang Ruiyang
Professional Degree Applied for:	Master of Applied Statistics
Speciality:	Applied Statistics
Cultivation ways:	Full-time
School:	School of Mathematics and Physics
Date of Defence:	June, 2024
Degree-Conferring-Institution:	North China Electric Power University

摘 要

随着循环经济理念日益深入人心，我国二手书市场正迎来新的发展机遇。互联网经济的蓬勃发展，为线上交易带来了更多资源，随之而来的是各类线上二手书交易平台应运而生，极大的促进了二手书市场的快速发展。因此，研究影响二手书价格的因素，建立合理的二手书定价机制具有重要意义。

本文基于孔夫子旧书网线上平台的二手书数据进行研究，通过定量分析二手书数据对二手书价格的定价模型提供理论依据。首先对抓取的数据按照定性变量和定量变量进行描述统计以及散点矩阵分析，以二手书的售价为目标变量，通过构建灰色关联度模型对影响因素进行定量分析，筛选特征变量，然后通过构建多元回归模型，对多水平的定性变量设置哑变量，对模型进行对数调优，通过回归系数解释各指标对二手书价格的影响，再然后构建 BP 神经网络模型，包括对网络模型输入输出指标的选择，误差控制范围、迭代次数、模型学习速率等参数的设计，以及网络训练，最后基于多元回归模型与 BP 神经网络模型，分别对测试集中的二手书价格进行预测，并对其预测结果进行对比分析。

结果表明，灰色关联度模型中的结论显示二手书的品相、书籍装帧、开本、页数、出版时间、版次、书籍所属学科门类以及二手书的定价这 8 个特征与二手书售价的关联度较高，且书籍定价与二手书的售价的灰色综合关联度为 0.805，相关性较强。从模型预测结果来看，BP 神经网络模型的预测结果图比回归模型的预测结果图更加贴近真实值，且 BP 神经网络模型的平均绝对误差（MAE）为 7.06 优于回归模型的平均绝对误差（MAE）10.39，BP 神经网络模型平均绝对误差百分比为 27.11% 优于回归模型的 45.47%，BP 神经网络模型的预测效果要优于回归模型，从而为二手书的定价提供了一个较为准确的预测模型。

最后，本文从微观的二手书个人卖家和二手书交易平台以及宏观的二手书市场营销策略三个方面对二手书市场的发展提出建议，旨在推动循环经济背景下二手书市场的可持续发展。

关键词：灰色关联模型；BP 神经网络模型；多元回归模型；二手书价格预测

Abstract

With the concept of circular economy becoming more and more popular, the second-hand book market in our country is ushering in new opportunities for development. The vigorous development of the Internet economy has brought more resources for online trading, followed by various online second-hand book trading platforms came into being, which greatly promoted the rapid development of the second-hand book market. Therefore, it is of great significance to study the factors affecting the price of second-hand books and establish a reasonable pricing mechanism for second-hand books.

Based on the second-hand book data on the platform of Confucius's second-hand book network, this paper provides a theoretical basis for the pricing model of second-hand book prices through quantitative analysis of second-hand book data. Firstly, descriptive statistics and scatter matrix analysis were carried out on the captured data according to qualitative and quantitative variables, and the selling price of used books was taken as the target variable. The influencing factors were quantitatively analyzed by building a grey relational degree model and the feature variables were screened. Then, dummy variables were set for the multi-level qualitative variables by building a multiple regression model, and the model was log-optimized. The regression coefficient is used to explain the impact of each index on the price of used books, and then the BP neural network model is constructed, including the selection of input and output indexes of the network model, the design of parameters such as error control range, number of iterations, model learning rate, and network training. Finally, based on the multiple regression model and BP neural network model, The prices of used books in the test set are predicted respectively, and the results are compared and analyzed.

The results show that the conclusion of the grey correlation degree model shows that the eight characteristics of the used book, such as the appearance, book binding, book opening, page number, publication time, edition, subject category of the book and the price of the used book are highly correlated with the price of the used book, and the grey comprehensive correlation degree between the book price and the price of the used book is 0.805, which is a strong correlation. From the perspective of model prediction results, the prediction result graph of BP neural network model is closer to the true value than that of regression model, and the mean absolute error (MAE) of BP neural network model is 7.06, which is better than the mean absolute

error (MAE) of regression model is 10.39. The average absolute error percentage of BP neural network model is 27.11%, which is better than 45.47% of the regression model. The prediction effect of BP neural network model is better than that of the regression model, thus providing a more accurate prediction model for the pricing of second-hand books.

Finally, this paper puts forward suggestions on the development of the second-hand book market from three aspects: micro individual sellers and second-hand book trading platform as well as macro second-hand book marketing strategy, aiming at promoting the sustainable development of the second-hand book market under the background of circular economy.

Key words: Grey correlation model, BP neural network model, Multiple regression model, Used book price forecast

目 录

第 1 章 绪论.....	1
1.1 研究背景.....	1
1.2 研究意义.....	2
1.3 国内外研究现状.....	3
1.3.1 国内研究现状.....	3
1.3.2 国外研究现状.....	4
1.3.3 二手商品价格预测模型研究方法综述	6
1.4 论文的组织架构.....	8
1.5 论文的创新点.....	8
第 2 章 相关理论基础	9
2.1 多元线性回归模型.....	9
2.1.1 基本概述.....	9
2.1.2 模型解决常用方法.....	9
2.2 灰色关联度模型.....	11
2.2.1 邓氏关联度.....	12
2.2.2 广义关联度.....	12
2.3 BP 神经网络预测模型.....	13
2.3.1 BP 网络神经元模型.....	13
2.3.2 多层神经网络结构.....	15
2.3.3 BP 神经网络算法.....	16
2.4 本章小结.....	17
第 3 章 交易价格影响因素的确定与分析	18
3.1 数据来源及抓取规则.....	18
3.2 数据特征及数据说明.....	18
3.2.1 目标特征.....	18
3.2.2 相关特征	18
3.3 影响因素的确定和关联性分析	20
3.3.1 数据类型划分以及编码.....	20
3.3.2 因变量的数据分布.....	20
3.4 灰色关联度分析.....	29
3.4.1 灰色绝对关联度.....	29
3.4.2 灰色相对关联度.....	30
3.4.3 灰色综合关联度.....	32
3.5 本章小结.....	32

第 4 章 二手书的交易价格预测33

4.1 多元线性回归模型的建立33

4.1.1 多元线性回归模型.....33

4.1.2 模型的建立与分析.....34

4.1.3 变量的多重共线性检验.....36

4.1.4 结果整理与分析.....36

4.2 BP 神经网络模型建立.....38

4.2.1 数据的归一化.....38

4.2.2 网络结构参数设计.....38

4.2.3 BP 神经网络训练.....39

4.3 模型的预测结果与评价指标比较40

4.3.1 评价指标.....40

4.3.2 模型预测结果与评价指标比较.....41

4.4 本章小结.....43

第 5 章 结论与展望44

5.1 工作内容总结.....44

5.2 相关建议.....44

5.3 工作展望.....45

参考文献.....47

第1章 绪论

1.1 研究背景

首先，二手书作为一种耐耗品因其具有易运输，交易方便等特性而具有较高的流通价值。在当前互联网构建的物流体系下，伴随着二手书自身的高流通价值，二手书市场必然会蓬勃发展。要论及二手书市场的起源，那从我们国家瀚如烟海的历史中可以看出，文人墨客淘二手书那是自古以来就有，早已屡见不鲜，就如元末明初的诗人宋濂在《送东阳马生序》中写到：“余幼时即嗜学，家贫，无以致书以观，每假借于藏书之家，手自笔录，计日以还”，可见古时候对于书籍的收藏与流通已经很普遍了。二手书里蕴含着浓厚的历史底蕴，里面的一笔一划，一页一折都是与之前的读者思想的碰撞，装帧设计与排版的印刷也有着鲜明的时代特点，所以二手书不仅具有阅读价值，同时还具备收藏价值，随着市场上新书价格的不断攀升，将会有越来越多的读者购买二手书。此外，二手书归根到底还是一件商品，那么作为商品就必然有价值和使用价值如果一本新书在被用户 1 阅读完后，那么对于用户 1 的使用价值就为 0，这时候这本书的价值还在，那么可以作为二手书流入市场，对于之后购买的用户皆有使用价值，在书籍未被损毁之前，那么可以一直流通，具体可以见下面的用户价值走向图^[1]：




图 1-1 二手书流通价值图

通过二手书价值走向图 1-1 可以看出，二手书具有较高的流通价值。

其次，国内市场不断发展，对二手书市场的要求日益增大。随着人民生活水平日益提高，读书可以使人们在忙碌的工作和生活中偷得浮生半日闲，所以越来越多的人加入到了阅读大军的行列中。在第十九次全国国民阅读调查结果发布一文中显示^[2]，2021 年我国成年国民综合阅读率为 81.6%，成年国民人均阅读纸质图书为 4.76 本，虽然各种媒介的阅读率都在上升，但是成年人的阅读方式还是以纸质书籍为主，随着纸质书籍的人均阅读本书逐年递增，这也给二手书的发展打下了基础。并且伴随着经济发展，我国出版行业也不断壮大，读

者接收到各类书籍种类繁多且数量庞大，这些书籍重复阅读率较低，社会出现大量的闲置书籍，对这些闲置书籍的处理给家庭与社会的处理带来了很大的压力，过去将旧书当成废品处理的方式造成了资源的浪费，对于二手书市场的完善和发展极为迫切。另外一方面，市场上对于二手书的需求也从未停止过，对于二手书的消费群体大致有三类：第一类是普通的群众，这部分人是最多的，他们是单纯的陶醉于书籍内容中的书虫，经常会购买一些经典名著，文学小说以及一些科幻大作，他们的阅读领域非常繁杂；第二类是众多高校在校生，这部分人多半是因为新书价格较为昂贵，所以无奈选择购买二手书，且他们对二手书的购买偏好非常固定，一般是他们自身所学专业息息相关，需求稳定；第三类是一些古籍藏书爱好者，他们乐忠于关注那些绝世孤本或者一版一印的书籍，可能是出于投资也可能是出于收藏，这些书籍普遍存在着较高的溢价。在互联网发展起来之前，将供求结合是可遇不可求的，但是随着互联网的发展，二手书平台成为了二手书交易的桥梁。

再次，在国家大力支持构建国内国外循环经济的背景下，国内的二手书平台如雨后春笋般蓬勃发展。线上二手书平台在国内的发展大致经历过这三个阶段，第一个阶段：萌芽期，在这个阶段，二手书市场还没有成型，大多数交易还是通过类似于 QQ 群、博客等社交媒体来进行交易；第二个阶段：垄断时期，2007 年孔夫子旧书网横空出世，这种 C2C 的运营模式一度让其份额占到市场的 95% 左右；第三个阶段：多足鼎立时期，这个阶段自 2017 年开始，多家二手书交易平台异军突起，多抓鱼、熊猫格子、漫游鲸等等都是这时候的产物，从此国内二手书市场进入均衡发展状态。

最后，当前众多线上二手书平台面临着很多行业问题，例如发展同质化，营销手段滞后，利润渠道简单，行业判断力低下，对二手书定价不合理不统一等问题，以目前的发展模式很难适应各类型读者的不同层次的多样化需求。虽然我们处在二手书市场发展的重要风口期，但是就目前学界在二手书市场领域的研究进度还是比较滞后，且成果产出少，不能和当前的市场发展形势相匹配。所以面对这些线上二手书平台的营销模式的研究以及对二手书的定价模型这些问题还有待继续梳理。

1.2 研究意义

本研究针对在线二手书平台的数据，对影响二手书价格的因素以及二手书的定价机理进行系统分析，具有一定的理论意义和实践意义。

理论意义：通过国内外二手书平台的比较研究，从而对国内二手书平台的营销模式创新提出建议，由于传统的二手书市场定价策略的实证研究相对匮乏，本文基于线上二手书网站的真实数据，探析二手书价格的影响因素并进行量化

分析，为规范二手书市场的定价机理提供了理论基础。

实践意义：通过对二手书平台复杂数据的特征选取，建立合理的二手书定价模型，从而促进大数据分析领域在二手书市场中的深层研究，为广大二手书平台以及二手书个人卖家在二手书定价中提供参考价值。

1.3 国内外研究现状

1.3.1 国内研究现状

二手书市场的国内研究现状：二手书市场在国内的研究方向主要归纳为三个分支，包括对二手书平台的二手书的定价问题研究、对影响消费者购买二手书的因素的研究以及对二手书平台的营销策略分析。

1.3.1.1 对二手书的定价问题研究

在对二手书定价问题的研究中，学者从供需关系，多空博弈以及信息对称等多角度开展了相应的研究。田杨^[3]认为二手书归根到底是一种商品，从商品的使用价值和价值受供需关系调配的角度出发，通过分析了教育类，专业类和大众类的不同种类书籍的需求价格弹性和其背后的原因给出了我们在图书定价中要根据各类图书需求价格弹性的不同合理的实施差别定价策略。张青^[4]首次运用了股票二级市场中的多头和空头博弈思维对孔夫子网站中高溢价图书的价格形成进行了分析，指出了高溢价图书形成的原因，最后给出了高溢价图书对在修订的图书的定价的参考价值。苏玲等^[5]指出以闲鱼为代表的 C2C 商业模式中二手市场与供应链回收之间的竞争，分析了闭环供应链下的最优定价决策和回收渠道选择。

张雅云等^[6]从二手书的周期性及季节性对于价格的影响出发，指出通过对季节性商品的销售特点以及商品周期衰退特点的考虑，建立了以价格与销量非线性关系为基础的动态定价模型，以最小化利润损失为目标，为平台定价提供有力的支撑。此外二手书平台的信息其实不是完全对称的，于是在最优定价问题上，买卖双方都在进行博弈，郑君君等^[7]指出针对风险投资中平台定价的问题，通过构建完全信息和不完全信息的博弈模型，讨论了参与者风险偏好的不同对均衡结果的影响，从理论上分析了各因素最终是如何达到纳什均衡的。

关大字^[8]从商业银行贷款定价角度出发，阐述了目前商业银行贷款定价方法中存在的问题，文章通过结合委托-代理框架，套用最优控制理论，给出一个信息不对称时的合理的贷款定价模型。

1.3.1.2 影响消费者购买二手书的因素研究

在探究影响消费者购买二手书的因素的研究中，杜学美等^[9]研究了在线评论对消费者购买意愿的影响模型，考虑了接收者专业能力作为调节因素。通过

分析在线评论功能价值类因素和接收者心理表征类因素对消费者购买意愿的影响,从而深入了解在线评论在消费者决策中的作用。根据消费者对二手市场所保持的心理态度进而影响消费行为的区别可以将消费者主题态度大体分为两个主要部分:(1)外显态度:个体可以意识到的,容易受到社会期望影响的;(2)内隐态度:个体无法意识到的,受个体以往经验的影响的,这是经典的双重态度模型理论^[10]。

在双重态度模型领域开展对消费者行为分析工作的主要学者有:李巧等^[11]提到如何弱化这些阻碍二手商品买卖的因素,结合解释水平理论和传染原则,通过实验得出增加心理距离会降低感知污染程度,从而促进消费者更愿意购买二手商品。刘永芳等^[12]研究表明对耐用品和非耐用品内隐和外显态度的一致性和预测行为会呈现不同的表征特点。

1.3.1.3 二手书平台的营销策略研究

学界对于二手书平台的营销策略研究早在 2010 年左右徐若之^[13]就曾指出二手书当时的关键问题是二手书如果不参与经济市场的循环,那么其所带来的是巨大的资源浪费,并最早提出建立区域性高校二手书市场,为二手书市场的规划与构思开创了先河。张阿源^[14]通过对当前国内网络旧书市场的运营模式和营销策略的梳理,得出众多二手书平台中需要一个强有力的头部起带动作用,才能与那些弱小的平台所形成的长尾形成有效的市场关联,为整个二手书市场发展提供了一个以经济学模型所建立的理论参考。郑青青^[15]提倡利用循环经济理念促进二手书产业发展,加强出版业与二手书市场的合作,培养专业化的二手书人才,从而建立网络二手书平台的信任体系。陈彤彤等^[16]指出现在平台所面临的一系列问题并以 Bookoff 二手交易平台为例,阐述了其营销理念,市场定位,独特的回收价格标准从而揭示了其成功的原因,最后为二手书平台的经营策略提出建议。

1.3.2 国外研究现状

二手书市场的国外研究现状主要分为为四类,包括不同国家的二手书市场的发展现状、影响消费者对二手商品购买的因素、国外二手书平台的营销策略研究以及对二手书市场最优定价问题的研究。

1.3.2.1 不同国家二手书市场的发展现状

(1) 美国的二手书市场:

二手书市场近几年在美国发展迅速。IPSOS 图书趋势研究提供了可靠的数据,统计显示美国成年读者在购买纸质书籍中,二手书的比例约占 1/7,意味着每购买 7 本书中就有一本是二手书,并且这一比例可能持续增长。根据针对二手书商进行的在线调查显示,预计 2003 年美国二手书市场销售总额达到 6.14

亿美元，其中半数以上的销售额来自网络渠道。同时，实体书店和网络书店兼营的经营者具有较大的市场竞争力，占据了 80%的市场份额。在美国的在线二手书网站中，亚马逊书店、Bamp、N.com 市场占有率较高且较为知名，而市场占有率较低的 Alibris 和 Abebooks 则是二手书市场发展的新兴力量，它们不仅在自己的平台销售二手书，同时也是大型网络书店与众多二手书商之间联络的媒介。通过网上检索的数据，整理得到美国二手书主流的在线交易平台及其对应的特点，以下将通过表格 1-1 给出：

表 1-1 美国主要二手书市场及其特征

二手书商名称	特点
Thriftbooks	购买流程完善，顾客容易找到自己所需要的书，且对二手书的成色分类细致
Alibris	与独立的专业卖家合作，吸引独立卖家，对于绝版书籍，可以向出版商申请个人定制
Abebooks	提供回购服务和免运费送全球服务
BookOutlet	价格极度便宜且含有大量儿童读本
Biblio	热衷于帮顾客找到珍惜藏书
Powell's Books	既是一个二手书店，同时也是一个书籍平台的社区，可以通过该社区认识世界上其他的爱好者
Better World Books	一个新旧二手书交易平台，同时可以浏览有声读物和 DVD 影像
Book Finder	可以按年份细化检索，从而为顾客找到合适的书籍

（2）日本的二手书市场：

日本的二手书市场呈现寡头垄断的行业特性，Bookoff 公司一家独大，Mitsutaka^[17]阐述了 Bookoff 的销售额和二手书市场份额在日本的占比越来越大，呈现寡头垄断趋势。

（3）欧洲的二手书市场：

英国的二手书交易市场蓬勃发展，吸引了许多海外企业进军本土市场，如 Alibris UK、Better World Books、Abebooks UK、Ebay UK 和 Amazon UK 等。同时，本土二手书交易网站也逐渐崛起，例如英国最大的二手书销售商 World of Books，目前英国效率最高、速度最快的卖书网站 We Buy Books。此外，英国国内还有众多线下二手书店，如 Any Amount of Books、Skoob Books、Barter Books 和 Troutmart Books，以满足消费者多样化的需求。

德国的二手书市场也是种类繁多，由于德国新书价格昂贵，许多购书者更倾向于选择二手书交易平台购买。德国的主要二手书交易平台有三家，分别是 Eurobach、Medimaps.de 和 Booklooker.de.Eurobach 是一个一站式集成搜索平台，可一键检索欧洲大部分二手书商的在线平台，包括但不限于亚马逊、Ebay 和

Abebooks 等。Medimaps.de 提供种类广泛的书籍选择,覆盖范围也较广,除了官网购买外,大多数平台都设有分店。而 Booklooker 则是一家去中心化平台,如同德国版的“孔夫子旧书网”。

1.3.2.2 研究影响消费者对二手商品购买的因素

在研究影响消费者对二手商品购买的因素问题中, Perez-Belis,Marta 等^[18]阐述了影响消费者购买二手电子设备或者维修已损坏的电子设备的因素,为 3E (electrical and electronic equipment) 产品的再利用做准备。Lang,Zhang 等^[19]主要研究了中国消费者参与二手闲置服装交易的动机和主要阻碍因素,文章首次运用结构方程模型 (SEM) 研究中国消费者的购物价值观和服装互换意向感知风险之间的关系,对理解中国消费者对二手交易市场的态度有着积极意义。

1.3.2.3 国外二手书平台的营销策略研究

对于国外二手书市场的营销策略研究中, Luo,Wang 等^[20]阐述构建一个旨在确定社区和电商交易平台对构建二手交易平台的“诚信”的综合影响,通过构建对影响在线二手交易平台的框架,来揭示在在线二手交易背景下,使用网络社区来获得最佳结果的一种渠道。

此外对二手交易平台策略的研究中, Xu,Tang 等^[21]带来一种新的思路,他们提出了用博弈论模型去讨论不同运营模式对参与各方有何影响。

1.3.2.4 二手书市场最优定价问题研究

国外对二手书市场的定价问题的相关研究中, Zhang,Fan 等^[22]阐述了由于数字产品缺乏完善的数字版权管理,所以面临被盗版的可能,所以文章从博弈论的角度将政府的版权执法纳入考量范围,建立一个合适的模型,来研究数字产品的定价策略和最优的盗版控制水平。Clerides^[23]分析了影响图书定价的原因,并表示市场引入时间对销售有着很大的影响包括对定价的影响。

1.3.3 二手商品价格预测模型研究方法综述

目前学界对于二手商品领域价格预测的研究主要集中于二手房及二手车领域,主要的分析方法大致可分为传统分析方法和机器学习方法两个方面。

1.3.3.1 传统分析方法

在对二手商品价格预测领域的传统分析方法主要是通过回归模型去实现,这主要是基于回归模型的复杂度不高,模型结果的解释度高且易于理解等优势。Chen^[24]等通过对影响肇庆市房价的因素选取,利用相关分析方法筛选出相关度较高的指标,并构建多元线性回归模型预测肇庆市 2021 年及以后的房价趋势。Swarnkar^[25]等将机器学习模型与多元回归模型引入到二手车价格预测领域,结果表明多元回归模型的预测精度最好。Putr^[26]等通过多元线性回归模型、岭回归、套索回归、随机森林回归和多项式回归这五种回归模型预测西努沙登加拉

省的房价，最后比较预测误差得出随机森林回归是最佳模型。Li^[27]等构建了一个广义线性回归模型去预测房屋价格。Singh^[28]等建立线性回归模型、随机森林模型以及梯度提升模型去预测房屋的销售价格，最中得出梯度提升模型效果最优。黄泽宇^[29]利用爬取在线网站二手房销售数据，选取指标构建多元线性回归模型预测二手房价格。荆皓天^[30]等筛选影响二手房价的价格因素，利用多元线性回归模型、改进的 Lasso 回归模型以及 BP 神经网络模型预测二手房价。Han^[31]等通过加权回归模型预测二手汽车价格。

1.3.3.2 机器学习方法

J^[32]等通过构建机器学习 (ML) 模型预测二手房的交易价格并创建 WEB 程序对客户进行价格预测；Wang^[33]等通过设计基于忆阻器的神经网络 (ANN)，对美国波士顿几个城镇的房价进行建模，发现结果较之前更接近目标数据。Liu^[34]等采用粒子群优化算法的最小二乘支持向量机模型预测二手房价格，通过与传统意义上的支持向量机模型对比，得出采用粒子群优化算法的支持向量机模型预测效果更好。Wang^[35]等通过近似规范化将住宅特征变量分布不满足正态性的问题解决，提高了特征价格模型和多元回归模型的预测精度。Jiang^[36]等基于神经网络模型，开发出新的期望回归神经网络 (ERNN) 模型，并提高了模型对房价预测的性能。Tai^[37]等提出一种基于退火动力学的相关向量回归算法 (ADLRVR) 模型预测房价，通过选取最优节点，证明 ADLRVR 模型预测结果优于 RVR 模型和 SVR 模型。Karamanou^[38]和 Sibindi^[39]均是利用 XGboost 模型预测房屋价格。丁飞^[40]基于改进的狮群算法和 BP 神经网络模型提高了二手房价格预测的准确度。李圆圆^[41]基于北京市二手房交易数据，通过构建 BP 神经网络模型预测北京市二手房价格。张望舒^[42]等通过 Lasso 回归筛选显著变量，之后构建随机森林模型预测二手房价格。

1.4 论文的组织架构




图 1-2 论文组织框架图

1.5 论文的创新点

(1) 研究方向创新：在国家倡导构建国内大循环为主体，国内国际双循环共同发展的循环经济背景下，二手书市场作为循环背景中的重要一环一定会有很大的市场前景，所以对二手书市场的研究有着很强的现实意义。

(2) 研究方法创新：创新性的使用多元回归模型和 BP 神经网络模型预测二手书的价格，研究结论中得到二手书价格模型，给众多二手书平台以及个人卖家提供了一个定价模型参考，切实解决了二手书市场面临的重要问题。

第 2 章 相关理论基础

2.1 多元线性回归模型

2.1.1 基本概述

回归分析^[43]是统计学中的一个重要分支，它是研究变量间数量依存关系的一类统计方法，用于描述因变量 Y 如何依赖于自变量 X 和误差项的方程称为回归模型。当涉及到一个自变量，且因变量 Y 与自变量 X 之间的关系为线性关系，则称为一元线性回归。多元线性回归模型是对一元回归模型的推广，主要研究多个自变量和因变量之间的相关关系，其基本原理是对 n 个样本，分别收集其因变量和 p 维自变量的数据，用 Y 表示因变量，用 $x_1, x_2, \dots, x_p$ (p 表示自变量的个数) 表示自变量，样本数据的排列形式如下表 2-1 所示：

表 2-1 多元变量的数据结构

样本序号	变量及数据					
	Y	x_1	x_2	x_3	$\dots$	x_p
1	Y_1	x_{11}	x_{12}	x_{13}	$\dots$	x_{1p}
2	Y_2	x_{21}	x_{22}	x_{23}	$\dots$	x_{2p}
3	Y_3	x_{31}	x_{32}	x_{33}	$\dots$	x_{3p}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	Y_n	x_{n1}	x_{n2}	x_{n3}	$\dots$	x_{np}

其一般形式是：

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon \tag{2-1}$$

由上表 2-1 所示， β_0 是回归方程的常数项， $\beta_1, \beta_2, \dots, \beta_p$ 是回归方程的回归系数， ε 为误差扰动项。现在求解 $\beta(i = 0, 1, 2, \dots, p)$ 的方法主要是通过最小二乘法求最优解，具体求解过程将在下节展开。

2.1.2 模型解决常用方法

最小二乘法的求解原理是算出一组参数估计量 $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_p)'$ ，让残差平方和最小：

$$Q(\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_p) = \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip})^2 \tag{2-2}$$

公式(2-2)我们可以利用微分学中对其求偏导来确定极值，下面给出具体做法：

对上述的未知参数求偏导，并令这些偏导数等于 0，则可知 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_p$ 满足方程：

$$\begin{cases} \left. \frac{\partial Q}{\partial \beta_0} \right|_{\beta_0=\hat{\beta}_0} = -2 \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip}) = 0 \\ \left. \frac{\partial Q}{\partial \beta_1} \right|_{\beta_1=\hat{\beta}_1} = -2 \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip}) x_{i1} = 0 \\ \left. \frac{\partial Q}{\partial \beta_2} \right|_{\beta_2=\hat{\beta}_2} = -2 \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip}) x_{i2} = 0 \\ \vdots \\ \left. \frac{\partial Q}{\partial \beta_p} \right|_{\beta_p=\hat{\beta}_p} = -2 \sum (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip}) x_{ip} = 0 \end{cases} \quad (2-3)$$

整理后得到：

$$\begin{cases} l_{11} \hat{\beta}_1 + l_{12} \hat{\beta}_2 + \dots + l_{1p} \hat{\beta}_p = l_{1y} \\ l_{21} \hat{\beta}_1 + l_{22} \hat{\beta}_2 + \dots + l_{2p} \hat{\beta}_p = l_{2y} \\ \vdots \\ l_{p1} \hat{\beta}_1 + l_{p2} \hat{\beta}_2 + \dots + l_{pp} \hat{\beta}_p = l_{py} \end{cases} \quad (2-4)$$

并且

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2 - \dots - \hat{\beta}_p \bar{x}_p \quad (2-5)$$

其中对于任何的 $a=1, \dots, n$ 和 $i, j=1, \dots, p$

$$\begin{aligned} l_{ij} = l_{ji} &= \sum_a (x_{ai} - \bar{x}_i)(x_{aj} - \bar{x}_j) = \sum_a x_{ai} x_{aj} - \frac{1}{n} (\sum_a x_{ai}) (\sum_a x_{aj}) \\ l_{iy} &= \sum_a (x_{ai} - \bar{x}_i)(Y_a - \bar{Y}) = \sum_a x_{ai} Y_a - \frac{1}{n} (\sum_a x_{ai} Y_a) (\sum_a Y_a) \end{aligned} \quad (2-6)$$

通过上面的求解步骤可以得出以下方程：

$$\begin{cases} \sum Y = n\hat{\beta}_0 + \hat{\beta}_1 \sum x_1 + \hat{\beta}_2 \sum x_2 + \dots + \hat{\beta}_p \sum x_p \\ \sum YX_1 = \hat{\beta}_0 \sum x_1 + \hat{\beta}_1 \sum x_1^2 + \hat{\beta}_2 \sum x_1x_2 + \dots + \hat{\beta}_p \sum x_px_1 \\ \sum YX_2 = \hat{\beta}_0 \sum x_2 + \hat{\beta}_1 \sum x_1x_2 + \hat{\beta}_2 \sum x_2^2 + \dots + \hat{\beta}_p \sum x_px_2 \\ \vdots \\ \sum YX_p = \hat{\beta}_0 \sum x_p + \hat{\beta}_1 \sum x_1x_p + \hat{\beta}_2 \sum x_2x_p + \dots + \hat{\beta}_p \sum x_p^2 \end{cases} \quad (2-7)$$

最终得出参数估计量的表达式如下：

$$\begin{aligned} \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2 - \dots - \hat{\beta}_p \bar{x}_p \\ \hat{\beta}_1 &= \frac{\sum YX_1 - \hat{\beta}_0 \sum x_1 - \hat{\beta}_2 \sum x_1x_2 - \dots - \hat{\beta}_p \sum x_px_1}{\sum x_1^2} \\ \hat{\beta}_2 &= \frac{\sum YX_2 - \hat{\beta}_0 \sum x_2 - \hat{\beta}_1 \sum x_1x_2 - \dots - \hat{\beta}_p \sum x_px_2}{\sum x_2^2} \\ &\vdots \\ \hat{\beta}_p &= \frac{\sum YX_p - \hat{\beta}_0 \sum x_p - \hat{\beta}_1 \sum x_1x_p - \dots - \hat{\beta}_{p-1} \sum x_{p-1}x_p}{\sum x_p^2} \end{aligned} \quad (2-8)$$

当然，在构建多元回归模型时，利用最小二乘法对模型的参数估计量进行估计时也可通过矩阵形式演算具体过程。以下是方程的矩阵形式：

$$X'(Y - X\hat{\beta}) = 0 \quad (2-9)$$

移项得： $XX'\hat{\beta} = XY$ 。当 $(XX')^{-1}$ 存在时，那么就得到了参数估计量：

$$\hat{\beta} = (XX')^{-1}XY \quad (2-10)$$

2.2 灰色关联度模型

灰色关联分析法是目前学者在处理数据量较小、模型影响因素复杂且模型数据分布不明显的情况下经常使用的关联分析方法。相较于一般的因子分析、主成分分析等传统意义上的相关性分析方法，灰色关联分析具有较大的优势。传统方法对样本数据有较高要求，需要样本数据规模庞大且服从特定的分布规律，否则很难得到准确的关联度。而灰色关联度分析巧妙地规避了这些限制，它更注重因素之间整体程度的比较。灰色关联度分析模型不是函数模型，而是序列模型，通过计算序列之间的关联度，可以综合分析因素之间的关联度，进而对某一特征进行综合评价。接下来将介绍几种常见的灰色关联度模型。

2.2.1 邓氏关联度

设系统特征行为序列为 $X_0(k) = (x_0(1), x_0(2), \dots, x_0(n))$ ，系统的相关因素行为序列为 $X_i(k) = (x_i(1), x_i(2), \dots, x_i(n), (i=1, 2, \dots, m))$ ，首先计算关联系数：

$$\xi_{0i}(k) = \frac{\min_i \min_k |X_0(k) - X_i(k)| + \rho \max_i \max_k |X_0(k) - X_i(k)|}{|X_0(k) - X_i(k)| + \rho \max_i \max_k |X_0(k) - X_i(k)|} \quad (2-11)$$

则关联度为：

$$\gamma(X_0, X_i) = \frac{1}{n} \sum_{i=1}^n \xi_{0i} \quad (2-12)$$

2.2.2 广义关联度

广义上的关联度^[44]包括灰色相对关联度、灰色绝对关联度、灰色综合关联度。灰色绝对关联度：设 $X_i = (x_i(1), x_i(2), \dots, x_i(n)), (i=0, 1, 2, \dots, m)$ ，

记折线 $(x_i(1) - x_i(1), x_i(2) - x_i(1), \dots, x_i(n) - x_i(1))$ 为 X_i^0

令 $S_i = \int_1^n X_i^0 dt$ ，则 $|S_i - S_0| = \left| \int_1^n (X_i^0 - X_0^0) dt \right|, (i=0, 1, 2, \dots, m)$

则灰色绝对关联度为：

$$\xi_{0i} = \frac{1 + |S_0| + |S_i|}{1 + |S_0| + |S_i| + |S_i - S_0|} \quad (2-13)$$

灰色相对关联度：

设序列 X_0 与 X_i 长度相同，且初值皆不为 0， x_0 与 x_i 分别为 X_0 与 X_i 的初像值，则称 x_0 与 x_i 的灰色绝对关联度为 X_0 与 X_i 的灰色相对关联度，记为 γ_{0i}

$$\gamma_{0i} = \frac{1 + |S_0| + |S_i|}{1 + |S_0| + |S_i| + |S_i - S_0|} \quad (2-14)$$

灰色综合关联度：

综合关联度是一个全面反映序列之间关联度的指标，不仅体现了序列间的相似程度，同时也反映出序列之间相对于初始点的变化速率。具体公式如下：

$$\rho_{0i} = \theta \varepsilon_{0i} + (1 - \theta) \gamma_{0i} \quad (2-15)$$

为了避免人为设定对序列本身的影响，这里的 θ 一般取 0.5。

2.3 BP 神经网络预测模型

20 世纪 80 年代^[45]，David Rumelhart、Geoffrey Hinton 以及 Williams 分别独立地给出 BP 算法的清楚表述，所谓 BP 神经网络又称为误差反向传播神经网络，它是一种多层的前向型神经网络。BP 神经网络中一般包括多个隐含层和输出层，其信号与误差的传播方向相反，从而可以逼近复杂程度较高的函数。目前在 BP 神经网络中的应用场景主要包括模式识别与分类、数据压缩以及函数逼近等方面。^[46]

2.3.1BP 网络神经元模型

正如前面提到的，BP 神经网络模型包含多个隐含层与输出层，所以本节主要介绍 BP 神经网络的神经元结构与常见的激活函数，从而让我们对其映射过程有一个大致的了解。




图 2-1 神经元模型示意图

图 2-1 中展示了一个具有 R 个输入的基本 BP 神经元模型结构，对每一个指标赋予权重后求和得到神经元模型的输入。神经元接收到来自其他 n 个神经元传递来的信号 $p_i(i=1,2,...,R)$ ，这些信号通过带权重的 $W_i(i=1,2,...,R)$ 的全连接组合将计算结果传递给神经元，并作为神经元的总输入 $\sum p_i\omega_i$ ，然后将神经元收到的总输入结果与神经元的阈值 θ 进行比较，最后通过激活函数 $f(\sum p_i\omega_i, \theta)$ 处理以产生神经元的输出层。人工神经元模型可以用以下数学表达式计算：

$$a=f(\sum p_i\omega_i-\theta),i=1,2,...,R \tag{2-16}$$

BP 神经网络属于多层网络模型，通过接收其他神经元的信号模拟生物神经元的作用机理，并且利用阈值判断神经元是否被激活最终影响总输出。以下列举常见的激活函数类型：

2.3.1.1 Sigmoid 函数




图 2-2 sigmoid 函数

其函数表达式为: $\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}$, 由其函数表达式可知, 其定义域在 $(-\infty, +\infty)$, 值域在 $(0,1)$, 由其图像可知, 在靠近定义域中心 0 时的变化速度快, 靠近两端时变化速率相对平缓。

2.3.1.2 Tanh 函数




图 2-3 Tanh 函数

其函数表达式为: $\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$, 由其函数表达式可知, 其定义域在 $(-\infty, +\infty)$, 值域在 $(-1,1)$, 其图像类似于 Sigmoid 函数, 但是值域相比 Sigmoid 函数拓宽了负区域, 这样使得节点取值的变化范围极大提高了。

2.3.1.3 ReLU 函数




图 2-4 Relu 函数

其函数表达式为： $ReLU(x) = \max(0, x)$ ，定义域为 $(-\infty, +\infty)$ ，值域为 $(0, 1)$ ，随着定义域的取值变大，函数值不断趋向于无穷。 $ReLU$ (Rectified-Liner-Units)全称为线性修正模型，是分段函数，弥补了 Sigmoid 和 Tanh 函数的梯度消失问题，计算复杂度低，因此 ReLU 也较为方便学者去学习和优化。

2.3.2 多层神经网络结构

前向型神经网络通常是具有一个或多个由 Sigmoid 激活函数神经元构成的隐含层，以及一个由线性神经元构成的输出层，多个具有非线性传递函数的神经元层是的网络可以学习输入和输出之间的非线性关系，而线性输出层使得网络可以产生 $[-1, +1]$ 的输出值。^[45]




图 2-5 单层神经网络输出示意图

上图 2-5 显示了一个具有 R 个输入，由 S 个 Sigmoid 神经元组成的单层网络，但是单层神经网络模型在非线性可分问题上有其局限性，所以需要引入多

层神经网络模型，具体过程是在输入输出层之间引入隐含层，每一层都有与其对应的激活函数的神经元，具体结构见下图 2-6:




图 2-6 多层神经网络输出示意图

2.3.3BP 神经网络算法

BP 神经网络算法基本原理就是信号前向传播，而误差反向传播，通过不断调节网络权重，从而使得误差最小，从而达到训练目的，其实现步骤如下：

(1) 导入训练集 $D = \{(x_k, y_k)\}$ ，确定隐含层节点数 l 以及输出层节点数 m ，同时确定学习率 η ，并且在 $(0,1)$ 范围内随机初始化网络中的权值 w_{ij}, w_{jk} 和阈值。

(2) 要计算前向传播的输出层，首先要计算隐含层的输出 H ，此时隐含层的阈值设为 a ，此时：

$$H_j = f\left(\sum_{i=1}^n w_{ij} - a_j\right), j=1,2,\dots,l \quad (2-17)$$

公式中， f 是激活函数，这时前向传播输出层的阈值设为 b ，那么可以计算出前向传播的总输出 O ：

$$O_k = \sum_{j=1}^l H_j w_{jk} - b_k, k=1,2,\dots,m \quad (2-18)$$

(3) 利用 BP 神经网络反向传播计算每一层的误差 δ ：

$$\delta_k = y_k - O_k, k=1,2,\dots,m \quad (2-19)$$

(4) 反向传播权值更新和阈值更新并进行迭代直到达到我们设置的误差范

围才停止迭代, 更新后的权值为:

$$w_{ij} = w_{ij} + \eta H_j (1 - H_j) x(i) \sum_{k=1}^m w_{jk} \delta_k \quad (2-20)$$

$$w_{jk} = w_{jk} + \eta H_j \delta_k \quad (2-21)$$

更新后的阈值为:

$$a_j = a_j + \eta H_j (1 - H_j) \sum_{k=1}^m w_{jk} \delta_k \quad (2-22)$$

$$b_k = b_k + \delta_k \quad (2-23)$$

2.4 本章小结

本章简要介绍了文章中主要用到的方法和基本原理。首先介绍了多元线性回归模型的概念和利用最小二乘法求解回归系数, 接着介绍了灰色关联模型的几种常见类型和基本概念, 从而引入灰色综合关联度, 最后介绍了机器学习中的 BP 神经网络模型的基本概念, 常见的激活函数以及基本神经元结构和神经网络模型结构, 并给出 BP 神经网络的算法计算过程。

第 3 章 交易价格影响因素的确定与分析

3.1 数据来源及抓取规则

数据来源：孔夫子旧书网在线二手书交易平台

抓取规则：本文利用八爪鱼软件对孔夫子旧书网在线二手书平台上的数据进行抓取，为了排除一些由于时间原因造成的滞后数据形成的误差，所以我们制定了统一的规则：

(1) 对于数据来源的两个书店检索前 8 页的数据；

(2) 每个页面检索 50 条数据；

通过以上的规则，我们一共检索了 800 条数据，剔除部分缺失值后，还剩下 704 条数据。每条记录共包含 9 个原始特征字段。

3.2 数据特征及数据说明

通过数据抓取，共采集到来自孔夫子旧书网的二手书售卖信息 704 条，其中包含 9 个原始特征字段。下面将对这 9 个原始指标构建指标特征体系，并对相关指标进行详细说明。

3.2.1 目标特征

本文旨在通过分析二手书交易数据来训练模型，最终预测二手书的合理价格，二手书的销售价格代表了现在这本二手书所对应市场的真实价值。故而本文最终选择以二手书的售价作为目标特征。

3.2.2 相关特征

考虑到对于二手书价格影响的因素的多样化，但是二手书籍作为直观的流通商品，影响其价格的因素比较明显，所以本文检索的二手书价格主要考虑以下几个因素：所属的书籍类别，出版时间，该书所出版的版次，书籍装帧情况，开本大小，书籍页数，二手书品相以及该书原来的定价。从二手书自身来说对其价格影响的主要因素是书籍的品相，装帧情况，开本以及页数；从二手书的价格来分析对其现在市场售价影响最大的是二手书的定价；从二手书的内容上来分析影响二手书价格的因素主要是二手书所属的学科类别；从出版的角度分析影响二手书价格的因素主要为出版时间和该书的版次。以上这些因素结合了影响二手书价格的表现因素和深层因素，让我们的分析更加严谨准确，从而抓住影响二手书定价的核心问题。为我们研究二手书的定价奠定了一个良好的基础。最终通过整理，本文选取了 8 个变量，分别是二手书的书籍类别（教辅童

书, 经管, 科技互联网, 文学小说, 社会文化, 艺术, 生活, 历史), 二手书的出版时间, 二手书的装帧情况 (平装, 精装), 二手书的定价, 二手书的版次 (第一版和非第一版), 二手书的开本 (12 开, 16 开, 32 开), 二手书湖的页数, 二手书湖的品相 (主要有 8 品, 85 品, 9 品, 95 品和全新)。将以上这 8 个变量归纳为四个主要部分, 分别是书籍的自身因素, 价格因素, 内容因素以及出版因素, 这四个部分将是影响二手书定价的自变量, 而二手书售价则为被解释变量, 即为因变量, 探究这些自变量对因变量是以何种方式定性或者定量影响将是我们这篇文章的主要工作。下面将通过表格 3-1 展示自变量和因变量以及相应的数据:

表 3-1 数据说明

变量类型		变量名	详细说明	取值范围	备注
因变量		二手书售价 (Price)	单位: 元	[3.2, 396]	-
特征变量	自身因素	品相 (Status)	定性变量, 共 4 个水平	85 品、9 品、95 品、全新	-
		装帧 (Binding)	定性变量, 共 2 个水平	平装、精装	-
		开本 (Folio)	定性变量, 共 3 个水平	12 开、16 开、32 开	-
		页数 (Pages)	单位: 页	[31, 2372]	-
	出版因素	出版时间 (Year)	单位: 年	[0, 60]	-
		版次 (Edition)	定性变量, 共 2 个水平	第一版、非第一版	版次为第二版及以上的合并为非第一版
	内容因素	所属门类 (Kind)	定性变量, 共 8 个水平	教辅童书, 经管, 科技互联网, 文学小说, 社会文化, 艺术, 生活, 历史	-
	价格因素	书籍定价 (Charge)	单位: 元	[5, 600]	官方发行定价

(1) 自身因素: 这主要涉及书籍本身可被消费者观察到的外部信息, 包括书本的开本、页数、装帧情况, 以及在流通过程中可能导致书本破损的品相情况。

(2) 出版因素: 在本文中, 出版因素主要指书本的出版时间和版次, 这对

衡量二手书的价值具有重要意义。

(3) 内容因素：内容因素主要指书本所涉及的学科门类，直接影响二手书的受众群体和潜在价值。

(4) 价格因素：在二手书交易中，价格因素最具代表性的是二手书的定价，对二手书在市场中的流通和平台的二次定价具有重要的参考意义。

3.3 影响因素的确定和关联性分析

3.3.1 数据类型划分以及编码

3.3.1.1 数据类型的划分

由于不同类别的数据需要采取不同的分析处理方式，因此在进行数据分析与特征处理之前，通常需要根据数据类型进行分类划分。在统计分析中，数据通常被分为定量数据和定性数据两种类型。根据以上分类规则，对收集到的在线二手书交易原始数据进行了类型划分，结果如下：

定性数据包括：书籍品相、书籍装帧、书籍开本、书籍版次以及所属的学科门类等五组原始特征数据。

定量数据包括：书本的页数、出版时间以及书籍的定价等三组原始特征数据。

3.3.1.2 定性数据的编码

定性数据，也叫分类型数据，通常是指有限类别的指标，且类别通常是字符串形式。对定性数据的类别进行编码，将分类变量进行量化，转化为数值型变量，以便于本文的模型构建和分析，本文对定性数据采用的编码方式为序列编码。编码结果如表 3-2：

表 3-2 编码数据

类别特征	类别编号
书籍品相	{八五品：1，九品：2，九五品：3，全新：4}
书籍装帧	{平装：1，精装：2}
书籍开本	{12 开：1，16 开：2，32 开：3}
书籍版次	{第一版书籍：1；非第一版书籍：2}
所属学科门类	{教辅童书：1，经管：2，科技互联网：3，文学小说：4，社会文化：5，艺术：6，生活：7，历史：8}

3.3.2 因变量的数据分布

本文研究的是众多因素对二手书的售价影响，由 SPSS 统计软件分析出书籍售价作为因变量呈现严重的右偏分布，因此我们对其采用对数变换，下图

3-1 是对数变换后的二手书售价频数直方图：




图 3-1 售价频数直方图

通过图 3-1 可以看出，二手书售价（以 10 为底的对数分布）呈现出大致的正态分布。尽管直方图和正态曲线显示出数据略微右偏，但这已基本不影响结果的准确性，二手书售价均值为 42.74 元，且大多数二手图书的售价在 10 至 100 元之间，显示出平价二手书更受顾客欢迎。价格过高或过低都可能导致顾客失去兴趣。这与现实情况一致，二手书市场的原则在于吸引顾客购买低于市场价格的廉价书籍。若价格过高，顾客将不再购买二手书，因此合适的定价对二手书市场至关重要。

3.3.2.1 定性数据的描述性统计

(1) 书籍类别的数据分布




图 3-2 书籍类别频数分布图

根据图 3-2，可以大致观察到二手书的书籍类别情况。数据显示，本文检索的数据中，文学小说和社会文化类图书的数量相对较多，这可能与这些书籍所吸引的广泛用户群体相关。其次是教辅童书和经管类书籍，而科技互联网、历史和艺术类书籍的比例最低，可能与这些书籍的专业用户群体有关。




图 3-3 书籍类别价格箱线图

从图3-3中看到，科技互联网的二手书价格要显著高于其他品类的二手书价格，且波动最小，极差也是最小的，历史类书籍和经管类书籍的波动很大，对应的是这两类书籍的价格方差和极差很大，根据箱线图给出的中位数按照大小依次是科技互联网76.5元，艺术44元，历史39元，经管35元，生活类30元，社会文化类28元，教辅童书类25元，文学小说类20元。

(2) 装帧的数据分布




图 3-4 书籍装帧频数分布图

从图 3-4 可以看出在二手书市场中，绝大部分书籍对应的是平装，因为既

然选择了二手书籍，那么装帧对于消费者肯定不是第一考虑因素，当然，由于一些精装二手书具有的收藏意义而带来的溢价效应是平装书籍无法代替的，所以也会有相应的用户群体。




图 3- 5 书籍装帧价格箱线图

对于装帧情况的描述性统计分析，我们可以得到精装书籍占比约为31.96%，而平装书占比约为68.04%，从上面的箱线图3-5中看，精装书籍的价格中位数明显高于平装书籍的价格中位数，且不论从从上下四分位数还是极值（排除扰动值）来看，精装书籍的价格都显著高于平装书籍，所以可见，装帧情况对于价格的影响十分显著，且精装二手书的价格中位数来到了69元，而平装二手书的价格仅为22元，可以看出差距明显，所以装帧情况是影响二手书售价的重要因素。

(3) 开本的数据分布




图 3- 6 书籍开本频数分布图

开本越小代表纸张越大，由图 3-6 可以看出 16 开和 32 开的二手书占据了

市场的绝大部分空间，12 开的书籍所占比例不大，这可能与其流通的便利性有关，当然书籍的开本越小对应的纸张越大，那么相应的价格肯定会相对较高。




图 3-7 书籍开本价格箱线图

对于开本的描述性统计我们可以得到12开的书籍较少，我们从704条数据中只收集到21条数据对应的二手书为12开，不过其价格较其他两种开本明显高也是显而易见的，其价格中位数为145元，16开的二手书籍有369条数据，占比最多为52.41%，其中位数为38元，32开的二手书籍数据有314条，占比44.60%。其价格中位数为20元，可见开本对售价的影响也是很显著的，开本越小，纸张越大，售价相对越高。

(4) 版次的数据分布




图 3-8 书籍版次频数分布图

由图 3-8 可以看出，二手书网站挂牌的大部分书籍均是第一版的二手书，这也与消费者追求原版的理念相吻合，非第一版的书籍由于其再版，导致与第

一版的书籍内容可能有所变动，所以在市场的需求不如第一版的书籍大。




图 3-9 书籍版次价格箱线图

由箱线图3-9所示，再版书籍所对应的二手书价格比第一版的价格要高一些，不过再版书籍的上下分位数差距有点大，所对应的方差较大，也就是再版书籍的价格波动比较大，且再版书籍的中位数为89.10元，而第一版的书籍价格中位数仅为28元。

(5) 品相的数据分布




图 3-10 书籍品相频数分布图

由图 3-10 的二手书品相分布可知，九品的书籍最多，九五品的二手书籍分布居第二位，其次是八五品，最后是全新的书籍，这也可以看出二手书网站深谙消费者的心理，品相为九品的书籍对于消费者来说可谓最优解，书籍的价格也适中，品相也相对较好，而九五品和全新的书籍因其品相过于好，相对来说价格略贵一般不是消费者的第一考量，而八五品是因为品相不好所以消费者的

认可度较低，导致其市场占比较低。




图 3- 11 书籍品相价格箱线图

从图3-11的箱线图能看出来，在排除扰动项后，可以看出随着品相的变好，二手书售价也在提高，85品的价格中位数为15元，9品的价格中位数为27元，95品的价格中位数为44.5元，全新书籍的价格中位数比95品略高为45.85元，可见二手书的品相越好，售价也相对越高，并且四种品相的书的售价中位数均在10-100元这个范围内，并且由上图可以看出85品的书籍的上下分位数差距较大，可以看出85品的二手书售价的方差较大，也就是对应价格波动较大。

3.3.2.2 定量数据的频数分布

对定量数据的分布分析主要是通过特征离散化，把连续特征分段，在对每一段区间的特征数据进行统计，因此定量数据的分布分析又可称作是连续特征离散化。

(1) 页数的频数分布

经统计发现，采集到的二手书数据中页数最大的为 2327 页，最小的为 31 页。其中整体页数的频数分布情况如图 3-12:




图 3-12 书籍页数频数分布直方图

将页数区间[31,2327]进行等距分组统计（将分组数量设为 84 组），可以发现 95%的二手书页数数据主要集中落在[100,857]之间。

(2) 出版时间的频数分布

经统计发现，采集到的二手书数据中年份最大的为距今 60 年为 1963 年出版的，最小的为 2023 年刚出版的。其中整体页数的频数分布情况如图 3-13：




图 3-13 书籍出版时间频数分布直方图

将年份区间[0, 60]进行等距分组统计（将分组数量设为 30 组），可以发现 95%的二手书年份数据主要集中落在[0, 40]之间。

(3) 定价的频数分布

经统计发现，采集到的二手书数据中定价最大的为 600 元，最小的仅售 5 元。其中整体定价的频数分布情况如图 3-14：




图 3-14 书籍定价频数分布直方图

将年份区间[5, 600]进行等距分组统计（将分组数量设为 120 组），可以发现 95%的二手书定价数据主要集中落在[10, 198]之间。

（4）定量变量的散点图矩阵：

定量变量之间的相关关系可以用散点图热力矩阵来体现，具体见图 3-15：




图 3-15 定量变量与售价的散点矩阵

由图 3-15 中的散点图矩阵可以看出页数，定价这两个特征变量与二手书的售价关联程度较高，而出版时间与二手书的售价的关联程度不那么明显，引入下一小节灰色关联度分析去定量判断特征变量与被预测变量的相关程度。

3.4 灰色关联度分析

下面是我们根据二手书的自身因素，价格因素，内容因素，出版因素等指标来进行影响因数与二手书价格之间的关联性分析。通过定量分析来验证指标选取的合理性与准确性。

设二手书售价为参考列 x_0 ，品相，装帧，开本，页数，定价，出版时间，版次，书籍所属门类，分别为 $x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8$ 对比列。量化规则与上一章中的编码规则保持一致。

3.4.1 灰色绝对关联度

(1) 原始序列集

x_0 与 $x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8$ 都是等长序列，每个序列都包括 704 个数据：
 $x_0 = (20, 12, \dots, 396.8), x_1 = (3, 2, \dots, 4), x_2 = (1, 1, \dots, 2) \dots x_8 = (1, 1, \dots, 8)$

(2) 序列始点零像化

对序列数据始点零像化，得：

$$x_0^0 = (0, -8, \dots, 376.8), x_1^0 = (0, -1, \dots, 1), x_2^0 = (0, 0, \dots, 1), x_8^0 = (0, 0, \dots, 7)$$

(3) 求解相关序列值

分别求 $|s_0|, |s_i|, |s_i - s_0|$ ，其中 $i = 1, 2, \dots, 8$

$$|s_0| = \left| \sum_{k=2}^{704} x_0^0(k) + \frac{1}{2} x_0^0(704) \right| \quad (3-1)$$

$$|s_i| = \left| \sum_{k=2}^{704} x_i^0(k) + \frac{1}{2} x_i^0(704) \right| \quad (3-2)$$

$$|s_i - s_0| = \left| \sum_{k=2}^{704} [x_i^0(k) - x_0^0(k)] + \frac{1}{2} [x_i^0(704) - x_0^0(704)] \right| \quad (3-3)$$

将数值分别代入公式(3-1)、(3-2)、(3-3)得到以下结果：

$$|s_0| = 16194.4, |s_1| = 485.5, |s_2| = 225.5, |s_3| = 6350, |s_4| = 74305,$$

$$|s_5| = 13091.30, |s_6| = 6940, |s_7| = 55.5, |s_8| = 2286.5;$$

$$|s_1 - s_0| = 16679.9, |s_2 - s_0| = 15968.9, |s_3 - s_0| = 22544.4,$$

$$|s_4 - s_0| = 58110.76, |s_5 - s_0| = 3103.1, |s_6 - s_0| = 9254.4,$$

$$|s_7-s_0|=16138.9, \quad |s_8-s_0|=13907.9$$

(4) 计算灰色绝对关联度

$$\varepsilon_{0i}=\frac{1+|s_0|+|s_i|}{1+|s_0|+|s_i|+|s_i-s_0|} \tag{3-4}$$

将数值代入到公式(3-4)中得到表 3-3 中的结果:

表 3-3 绝对关联度

绝对关联度	数值
ε_{01}	0.500014
ε_{02}	0.506978
ε_{03}	0.500011
ε_{04}	0.608975
ε_{05}	0.904195
ε_{06}	0.714280
ε_{07}	0.501729
ε_{08}	0.570609

(5) 结果分析

从灰色绝对关联度中我们可以看到书籍定价与二手书售价的关联度最高 0.904195, 此外品相, 页数, 书籍所属学科门类与二手书的售价关联度也相对较高, 说明二手书的自身因素和内容因素对二手书价格的显著性影响, 此外二手书的出版因素与二手书售价的绝对关联度也在 0.5 以上, 说明选取的指标与二手书售价具有一定的关联性。

3.4.2 灰色相对关联度

(1) 原始序列集

x_0 与 $x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8$ 都是等长序列, 每个序列都包括 704 个数据:

$$x_0=(20,12,...396.8), x_1=(3,2,...,4), x_2=(1,1,...2) \dots x_8=(1,1,...,8)$$

(2) 序列初值化

求初值像, 得 $\hat{x}_0=(1,0.6,...,19.84), \quad \hat{x}_1=(1,\frac{2}{3},...,\frac{4}{3}), \quad \hat{x}_2=(1,1,...,2), \quad \dots$

$$\hat{x}_8=(1,1,...,8)$$

(3) 序列数据始点零像化

对序列数据始点零像化, 得到 $\hat{x}_0^0=(0,-0.4,...,18.84), \quad \hat{x}_1^0=(0,-\frac{1}{3},...,\frac{1}{3}),$

$$\hat{x}_2^0=(0,0,...,1), \quad \dots \hat{x}_8^0=(0.0,...,7)$$

(4) 求解相关序列值

分别求出 $|\dot{x}_0|,|\dot{x}_i|,|\dot{x}_i-\dot{x}_0|$ ，其中 $i=1,2,...,8$

$$|\dot{x}_0|=\left|\sum_{k=2}^{704}\dot{x}_0^0(k)+\frac{1}{2}\dot{x}_0^0(704)\right| \tag{3-5}$$

$$|\dot{x}_i|=\left|\sum_{k=2}^{704}\dot{x}_i^0(k)+\frac{1}{2}\dot{x}_i^0(704)\right| \tag{3-6}$$

$$|\dot{x}_i-\dot{x}_0|=\left|\sum_{k=2}^{704}[\dot{x}_i^0(k)-\dot{x}_0^0(k)]+\frac{1}{2}[\dot{x}_i^0(704)-\dot{x}_0^0(704)]\right| \tag{3-7}$$

将数值代入到公式(3-5)、(3-6)、(3-7)得到如下结果：

$$|\dot{x}_0|=809.72，|\dot{x}_1|=161.83，|\dot{x}_2|=225.5，|\dot{x}_3|=198.44，|\dot{x}_4|=290.256，$$

$$|\dot{x}_5|=331.42，|\dot{x}_6|=55.5，|\dot{x}_7|=6940，|\dot{x}_8|=2286.5；$$

$$|\dot{x}_1-\dot{x}_0|=971.55，|\dot{x}_2-\dot{x}_0|=566.38，|\dot{x}_3-\dot{x}_0|=988.69，|\dot{x}_4-\dot{x}_0|=506.66，$$

$$|\dot{x}_5-\dot{x}_0|=473.62，|\dot{x}_6-\dot{x}_0|=736.38，|\dot{x}_7-\dot{x}_0|=6149.12，|\dot{x}_8-\dot{x}_0|=1488.62$$

(5) 计算灰色相对关联度

$$\gamma_{0i}=\frac{1+|\dot{x}_0|+|\dot{x}_i|}{1+|\dot{x}_0|+|\dot{x}_i|+|\dot{x}_i-\dot{x}_0|} \tag{3-8}$$

将数值代入公式(3-8)中得到表 3-4 相对关联度：

表 3-4 相对关联度

相对关联度	数值
γ_{01}	0.500257
γ_{02}	0.646587
γ_{03}	0.505123
γ_{04}	0.684842
γ_{05}	0.706875
γ_{06}	0.540509
γ_{07}	0.557612
γ_{08}	0.675388

(6) 结果分析

从灰色相对关联度可以看出装帧，定价，页数和所属学科种类与二手书的售价关联度较高，且都维持在 0.7 附近，此外我们参考的其他因素与二手书售价的关联度也都在 0.5 以上。灰色相对关联度仅仅反映出了序列较初始点的变化速率大小，考虑到关联度的一般性和普遍性，因此我们通常会采用灰色综合关联度去确定各指标与二手书售价的关联度。

3.4.3 灰色综合关联度

序列 x_0 和 x_i 长度相同， $i=1,2,...,8$ 且初值皆不为 0。 ε_{0i} 和 γ_{0i} 分别表示 x_0 和 x_i 的灰色绝对关联度和灰色相对关联度， $\theta \in [0,1]$ ，那么则有：

$$\rho_{0i} = \theta\varepsilon_{0i} + (1-\theta)\gamma_{0i} \tag{3-9}$$

为 x_0 和 x_i 的综合关联度。因为绝对关联度和相对关联度参照的角度不同，所以本文取 $\theta=0.5$ ，以此计算，得到 x_0 和 x_i 的综合关联度见表 3-5：

表 3- 5 综合关联度

综合关联度	数值
ρ_{01}	0.500135
ρ_{02}	0.576783
ρ_{03}	0.502567
ρ_{04}	0.646908
ρ_{05}	0.805535
ρ_{06}	0.627395
ρ_{07}	0.529671
ρ_{08}	0.622999

灰色综合关联度作为我们选取的最终准则，更加全面的揭示了影响因素与二手书售价的相关关系。可以从最后的灰色综合关联度表中看出，品相，页数，定价，出版时间以及所属学科门类对于二手书的售价影响相对较大，装帧，开本以及版次的关联度也都大于 0.5，综上所述，我们选取的指标对二手书售价的影响十分显著。

3.5 本章小结

本章内容先简要介绍数据采集的过程及原则，之后对数据进行预处理，并通过描述统计以及散点矩阵对特征变量之间的相关关系有一个初步分析，最后通过灰色关联模型来定量分析特征变量与预测变量之间的相关关系，从而确定影响因素，为接下来的价格预测模型构建做了前期的准备。

第 4 章 二手书的交易价格预测

4.1 多元线性回归模型的建立

4.1.1 多元线性回归模型

(1) 哑变量设置

在构建多元线性回归模型时，如果当自变量 x_i 为连续变量，那此时回归系数 β 可以解释为：在其他自变量保持不变的条件下， x 每改变一个单位所引起的因变量 y 的平均变化量。如果自变量 x_j 为二分类变量，例如装帧情况（平装为1，精装为2），我们可以将其改变为有无精装，即平装为0，精装为1，那么这时回归系数 β 能够被解释为：在保持其他特征变量不变的情况下，精装书籍相对于平装书籍，影响二手书售价的平均值。如果自变量 x_k 为多分类变量时，例如书籍类别，开本，品相等多分类变量，那么这时候仅用一个回归系数 β 去解释多分类变量所包含的不同类别对于二手书售价的影响，结果可能达不到预期。所以在建模之前，会将原始的三个多分类变量书籍类别，开本，品相转化为哑变量，每个哑变量仅代表不同类别之间的差异，此时在构建多元线性回归模型时，多分类变量的每个类别都有其对应的回归系数，从而使回归的结果更容易解释，更具有实际意义。书籍类别一共有8类，分别是教辅童书，经管，科技互联网，文学小说，社会文化，艺术，生活，历史，根据哑变量的编码原理，设置 $k-1$ 个，即7个哑变量。选择价格中位数最低的文学小说类作为基准，那么书籍分类多变量的自变量赋值见表4-1：

表 4-1 书籍类别的哑变量赋值

书籍分类	哑变量值						
教辅童书	1	0	0	0	0	0	0
经管	0	1	0	0	0	0	0
科技互联网	0	0	1	0	0	0	0
社会文化	0	0	0	1	0	0	0
艺术	0	0	0	0	1	0	0
生活	0	0	0	0	0	1	0
历史	0	0	0	0	0	0	1

书籍开本一共有三个分类，分别是12开，16开，32开，此时我们设置两个哑变量，将价格中位数最低的32开作为基准，那么书籍开本多变量的自变量赋值见表4-2：

表 4-2 书籍开本的哑变量赋值

开本	哑变量值	
12开	1	0
16开	0	1

二手书品相一共有四个分类，分别是全新，95品，9品，85品，取价格中位数最低的85品为基准，设置三个哑变量，那么此时品相多变量的自变量赋值见表4-3：

表 4-3 书籍品相的哑变量赋值

品相	哑变量值		
全新	1	0	0
九五品	0	1	0
九品	0	0	1

(2) 模型选择

对于模型的考量，常见的特征价格模型主要为简单线性回归模型、对数线性回归模型，通过SPSS对这两种模型进行回归分析，对比可决判定系数（ R^2 ）与调整后的可决判定系数（调整后 R^2 ），选出最优模型去构建二手书价格特征模型，两种模型的拟合效果如表4-4所示：

表 4-4 两种模型拟合效果

模型	R^2	调整后 R^2
简单线性回归模型	0.659	0.655
对数回归模型	0.788	0.786

针对回归模型，主要通过可决系数 R^2 来衡量模型的拟合优度， R^2 的取值范围在0-1之间， R^2 越接近1，说明回归模型拟合程度越好；反之， R^2 的值越接近0，说明拟合效果越差，由上表4-4可以得到简单线性回归模型与对数回归模型的可决系数 R^2 分别为0.659、0.788，对数模型拟合效果要更好，因此初步假定的对数回归模型为：

$$\lg y = b + \sum \beta_i x_{\text{书籍类别}} + \sum \beta_j x_{\text{开本}} + \sum \beta_k x_{\text{品相}} + \beta x_{\text{装帧}} + \beta x_{\text{定价}} + \beta x_{\text{页数}} + \beta x_{\text{出版时间}} + \beta x_{\text{版次}}$$

4.1.2 模型的建立与分析

模型的建立选取了三个连续性变量，分别为书籍定价 $x_{\text{定价}}$ ，书籍页数 $x_{\text{页数}}$ ，书籍出版时间 $x_{\text{出版时间}}$ ，针对另外的定性变量书籍类别，开本，装帧，品相和版次，分别选取了文学小说，32 开，平装书，85 品和第一版作为参照组并设置了哑变量，得到结果如表 4-5：

表 4-5 回归结果

模型	非标准化系数		标准化系数	t	显著性
	B	标准误差	贝塔		
(常量)	1.181	.031		38.079	.000
出版时间	-.012	.001	-.0267	-11.845	.000
页数	.000	.000	.149	5.473	.000
书籍定价	0.002	.000	.334	9.324	.000
全新	.089	.031	.008	.281	.009

表 4-5 (续表)

九五品	.124	.026	.131	4.810	.000
九品	.081	.021	.107	3.885	.000
开本 16	.106	.015	.140	7.204	.000
开本 12	.119	.049	.054	2.412	.016
版次 1	-.006	.030	-.004	-.189	.085
装帧 1	.201	.019	.248	10.748	.000
教辅童书	-.168	.024	-.145	-6.913	.000
经管	-.076	.024	-.067	-3.153	.002
科技互联网	.155	.031	.106	5.044	.000
社会文化	.027	.020	.030	1.356	.175
艺术	.092	.031	.058	2.953	.003
生活	.025	.028	.017	.877	.181
历史	.056	.027	.043	2.097	.036

此时的可决系数 R^2 为 0.788, 效果良好, 但是从表格 4-4 中看到连续性变量书籍页数的回归系数为 0, 为了避免此结果的出现, 所以我们同时对二手书的页数取对数, 得到表 4-6 的回归结果:

表 4-6 调整后的的回归分析结果表

模型	非标准化系数		标准化系数	t	显著性
	B	标准误差	贝塔		
(常量)	.473	.095		4.977	.000
出版时间	-.011	.001	-.0260	-11.899	.000
页数的对数	.319	.038	.190	8.438	.000
书籍定价	.002	.000	.348	11.502	.000
全新	.109	.030	.003	.105	.000
九五品	.129	.025	.136	5.161	.000
九品	.082	.020	.108	4.035	.000
开本 16	.092	.014	.122	6.405	.000
开本 12	.134	.048	.060	2.795	.005
版次 1	-.016	.029	-.012	-.563	.054
装帧 1	.186	.018	.229	10.156	.000
教辅童书	-.144	.024	-.125	-6.053	.000
经管	-.072	.023	-.064	-3.098	.002
科技互联网	.155	.029	.106	5.253	.000
社会文化	.033	.020	.036	1.701	.089
艺术	.099	.030	.062	3.264	.001
生活	.035	.027	.024	1.273	.123
历史	.062	.026	.047	2.405	.016

经过对二手书的页数取对数后, 由表 4-5 可知, 在 $\alpha = 0.1$ 的显著性水平下, 书籍类别中生活类书籍相对于参照组的文学小说类书籍对二手书的售价影响没有显著性差别, 其余变量均通过显著性检验。此时, 模型的 R^2 为 0.800, 较之前有了明显的提升, 表明本文对二手书的页数取对数是合理有效的, 此时调整后的模型为:

$$\lg y = b + \sum \beta_i x_{\text{书籍类别}} + \sum \beta_j x_{\text{开本}} + \sum \beta_k x_{\text{品相}} + \beta x_{\text{装帧}} + \beta x_{\text{定价}} + \beta \lg x_{\text{页数}} + \beta x_{\text{出版时间}} + \beta x_{\text{版次}}$$

4.1.3 变量的多重共线性检验

由于书籍定价和书籍的页数，开本和装帧的可能的相关性较高，为避免回归模型特征变量之间高度相关性对模型预测结果的干扰，因此要对这四组变量做多重共线性检验，见表 4-7：

表 4-7 多重共线性检验

变量	容差	VIF
书籍定价	.319	3.137
页数的对数	.577	1.733
开本 12	.626	1.597
开本 16	.803	1.245
装帧	.573	1.745

由上表4-7可知，四组变量之间的VIF均< 10，所以变量间不存在多重共线性，回归分析有效，不需要进行主成分分析，调整后的 R^2 为0.795，符合回归分析要求。

4.1.4 结果整理与分析

在将上述结果整理之后，得到如下回归模型系数表 4-8：

表 4-8 回归系数

变量名		回归系数	备注
出版时间		-.011	
页数的对数		.319	
书籍定价		.002	
品相	全新	0.109	以85品为参照
	95品	.129	
	9品	.082	
装帧		.186	以平装为参照
版次		-.016	以非第一版为参照
开本	12开	.134	以32开为参照
	16开	.092	
书籍类别	教辅童书	-.144	以文学小说为参照
	经管	-.072	
	科技互联网	.155	
	社会文化	.033	
	艺术	.099	
	历史	.062	
	生活	-	以文学小说为参照没有显著性差异

综上所述，最终得到回归模型为：

$$\lg y = 0.473 + \sum \beta_i x_{\text{书籍类别}} + \sum \beta_j x_{\text{开本}} + \sum \beta_k x_{\text{品相}} + 0.186x_{\text{装帧}} + 0.002x_{\text{定价}} \\ + 0.319\lg x_{\text{页数}} - 0.011x_{\text{出版时间}} - 0.016x_{\text{版次}}$$

在控制其他因素不变的情况下，对于模型采用的回归分析结果可以得出如下结论：

- (1) 出版时间的回归系数为-0.011，在保持其他变量不变的情况下，出版时间每变动一个单位，相应的二手书售价的对数也会变动 0.011 个单位。
- (2) 书籍页数的对数的回归系数为 0.319，在保持其他变量不变的情况下，页数的对数每变动一个单位，那么二手书售价的对数也会变动 0.319 个单位。
- (3) 书籍定价每变动一个单位，相应的二手书售价的对数也就变动 0.002 单位。
- (4) 从品相角度分析，在保持其他变量不变的情况下，全新书籍的售价的对数比 85 品的书籍售价的对数高 10.9%，95 品相的二手书平均售价的对数比 85 品相的二手书平均售价的对数高 12.9%，9 品的二手书平均售价的对数比 85 品的二手书平均售价的对数高 8.2%。
- (5) 从装帧的角度分析，在保持其他变量不变的情况下，精装二手书的平均售价的对数比平装二手书的平均售价的对数高 18.6%。
- (6) 从开本的角度分析，在保持其他变量不变的情况下，12 开的二手书平均售价的对数比 32 开二手书平均售价的对数高 13.4%，16 开的二手书平均售价的对数比 32 开二手书平均售价的对数高 9.2%。
- (7) 从书籍类别的角度分析，在保持其他变量不变的情况下，教辅童书类二手书平均售价的对数比文学小说类二手书平均售价的对数低 14.4%，经管类的二手书平均售价的对数比文学小说类的二手书平均售价的对数低 7.2%，科技互联网类的二手书平均售价的对数比文学小说类的二手书平均售价的对数高 15.5%，艺术类的二手书平均售价的对数比文学小说类的二手书平均售价的对数高 9.9%，历史类的二手书平均售价的对数比文学小说类的二手书平均售价的对数高 6.2%，。社会文化类的二手书平均售价的对数比文学小说类的二手书平均售价的对数高 3.3%，生活类与文学小说类的售价无显著性差异。
- (8) 从书籍的版次角度分析，在保持其他变量不变的情况下，第一版的书籍比非第一版的书籍的平均售价的对数低 1.6%。

4.2 BP 神经网络模型建立

4.2.1 数据的归一化

文章将二手书的售价作为网络目标输出的神经元，将影响二手书价格的 8 个因素作为输入神经元。在建立神经网络模型进行预测之前，由于所选择的影响因素的量纲不统一所造成的影响不能忽视，因此我们要对数据进行预处理，即数据的归一化处理以此来消除量纲不同所带来的影响。数据归一化的原理是把各序列数据转化到 $[0,1]$ 范围内，从而消除不同影响因素数据之间量级的差异，减小系统误差，一般通过以下两种方法实现：

(1) 最大最小法：函数形式为 $x_k = \frac{x_k - x_{\min}}{x_{\max} - x_{\min}}$ ，其中 $x_{\min}$ 为序列最小值， $x_{\max}$ 为序列最大值。

(2) 平均数方差法：函数形式为 $x_k = \frac{x_k - x_{\text{mean}}}{x_{\text{var}}}$ ，其中 x_{mean} 为序列均值， x_{var} 为序列方差。

本节采用的是 MATLAB 中自带的函数 Mapminmax 对数据进行归一化，其原理为最大最小法。

4.2.2 网络结构参数设计

(1) 输入及输出指标的选取：针对二手书售价的影响因素本文选取了 8 个指标，对应 BP 神经网络的输入神经元一共有 8 个；输出指标为二手书售价的预测结果。

(2) 隐含层与节点数的选择：文章选择 S 型连续函数，隐含层数设为 1，隐含层的节点数通常与输入神经元的个数有关，输入神经元个数为 m ，那么隐含层节点数一般为 $2m+1$ ，本文中输入神经元个数为 8，所以我们选择 17 作为我们隐含层的节点数。

(3) 网络参数设计：我们将神经网络模型中的网络迭代次数设为 500，学习速率设置为 0.01，预测误差控制在 10^{-3} ，训练集和测试集按照 8:2 划分，最后通过误差收敛来判断模型的预测效果。

4.2.3BP 神经网络训练

选取 8 个输入神经元，1 个输出神经元，输出层为 1，隐含层为 1，隐含层节点数为 17，网络迭代次数为 500，学习速率为 0.01，误差控制在 10^{-3} ，以下图 4-1 为网络训练的基本过程：




图 4-1 训练网络

接着通过 MATLAB 对模型进行迭代，得到以下的误差收敛图 4-2：




图 4-2 最优迭代次数

从图 4-2 上的收敛结果可以看出：网络训练 6 次之后收敛，网络误差为 0.00066185，完全达到我们设置的误差范围的要求。纵坐标为误差大小，可以看出，随着迭代次数的增多，误差越来越小，并趋于稳定，此时证明我们模型训练效果优秀。




图 4-3 模型拟合效果

由图 4-3 可以看出训练集样本的拟合优度为 98.792%，测试集的拟合优度为 96.731%，而全部的拟合优度也达到了 98.32%，这表明 BP 神经网络模型的拟合效果较好，可以采用 BP 神经网络模型对二手书的价格进行预测。

4.3 模型的预测结果与评价指标比较

4.3.1 评价指标

在模型构建完成后，需要对模型的预测结果进行判别评价，那么就需要引入相应的模型评价指标体系，通过计算相应的误差指标来比较模型的预测性能，误差越小模型越优良，- 常见误差预测指标如下：

(1) 均方误差 (MSE)：均方误是指模型估计值与测试集的真实值之间误差平方和的代数平均值，其计算公式如下：

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \quad (4-1)$$

(2) 均方根误差 (RMSE)：该误差指标是指均方误差的算术平方根，又

可称作标准误差，具体公式如下：

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (4-2)$$

(3) 平均绝对误差 (MAE)：平均绝对误差是指模型预测值与测试集真实值之间的误差的绝对值的代数平均，其公式如下：

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (4-3)$$

(4) 平均绝对误差百分比 (MAPE)：该指标是指模型预测值与测试集数据真实值之间误差绝对值与真实值之间的误差百分比，具体公式如下：

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right| \times 100\% \quad (4-4)$$

其中 n 代表样本个数， y_i 代表样本的真实值， $\hat{y}_i$ 代表模型预测模型给出的估计值。由公式 4-1 可以看出计算均方误的过程中对预测值与真实值之间做了离差平方处理，导致计算出的误差数值较大，不利于直观比较模型的预测性能。为了避免上述情况出现从而更好更直观的比较两种模型的预测性能，本文最终选择 MAE 和 MAPE 作为检验两种模型预测性能的指标。

4.3.2 模型预测结果与评价指标比较

(1) 模型预测结果比较

经过上述 4.1 节以及 4.2 节构建模型以及模型调优后，将测试集中的数据带入训练好的模型中进行预测，最终给出多元回归模型、BP 神经网络模型对预测集 140 条数据的价格预测，分别如图 4-4，图 4-5：




图 4-4BP 神经网络预测结果图

图 4-4 为 BP 神经网络价格预测结果图，其中蓝色的点为神经网络预测值，红色的点为测试集中样本的真实值，由图 4-4 可见，我们 BP 神经网络模型预测的误差较小。




图 4-5 回归模型预测结果图

图 4-5 为回归模型价格预测的结果图，其中蓝色的点为回归模型的价格预测值，红色的点为测试集中的样本真实值，由图 4-5 可以看出蓝色的离群值显著增多，且误差较大，可见回归模型的误差效果显著劣于 BP 神经网络模型。为了让预测结果对比更加直观，本文将两种模型的预测结果绘入同一张图中，具体见下图 4-6：




图 4-6 预测结果比较图

图 4-6 中，蓝色的点代表测试集中的样本真实值，红色的点代表 BP 神经网络模型测试集中预测值，黄色的点代表回归模型预测的结果值，由图 4-6 可知，黄色的点较红色的点误差显著增大，可见 BP 神经网络模型的预测误差要小于回归模型，由此可见，BP 神经网络模型的预测性能优于回归模型。

(2) 模型评价指标比较

表 4-9 模型预测误差比较

模型类别	平均绝对误差	平均绝对百分比误差
传统多元回归模型	10.39	45.47%
BP 神经网络模型	7.06	27.11%

如表 4-9 所示，BP 神经网络模型无论是从平均绝对误差（MAE）、平均绝对百分比误差（MAPE）来看，预测效果都要远远优于多元回归模型，对于孔夫子旧书网的二手书价格的预测效果更好。

4.4 本章小结

本节内容主要是通过构建多元回归模型与 BP 神经网络模型，并分别对测试集中的数据进行预测，并利用可视化的误差结果和所选取的误差指标对模型的预测效果进行比较，从而得出 BP 神经网络模型的预测效果更好。

第 5 章 结论与展望

5.1 工作内容总结

本文在研究国内外二手商品的相关文献基础上，针对国内当前最大的二手书在线交易平台孔夫子旧书网的图书价格进行统计分析。首先通过数据处理以及描述统计定性分析可能影响二手书价格的相关因素，接着通过灰色关联判别定量分析所选取的书籍特征与二手书价格的关联度，并最终确定 8 个显著特征；基于筛选的指标，通过构建多元回归模型和 BP 神经网络模型对二手书价格进行预测，并比较预测结果，判断模型的优劣性。本文的研究成果与结论如下：

(1) 确立影响二手书价格的特征变量，本文再梳理相关文献的基础上，结合二手书在线平台的书籍销售特征，筛选出可能影响二手书价格的相关特征，接着构建灰色关联度模型，通过计算灰色绝对关联度和灰色相对关联度，最后得出灰色综合关联度，并确定选取的特征变量的合理性，从而确定影响二手书价格的相关变量，其中包括书籍的自身因素（品相，装帧，开本，页数），出版因素（出版时间以及版次），内容因素（所属的学科门类：教辅童书，经管，科技互联网，文学小说，社会文化，艺术，生活，历史），价格因素（二手书定价）。

(2) 基于筛选出的 8 个特征因素，首先构建多元回归模型，通过对多水平的定性变量设置哑变量，选取合适的模型准则，最后对模型进行对数调优，得到基于多元回归模型的特征价格模型，模型的拟合优度为 0.8；之后构建 BP 神经网络模型，包括对网络模型输入输出指标的选择，误差控制范围、迭代次数、模型学习速率等参数的设计，以及网络训练，得到基于 BP 神经网络模型的特征价格模型，模型的拟合优度为 0.95 以上。

(3) 对两种模型的预测结果进行比较分析，本文分别构建了多元回归模型以及 BP 神经网络模型对测试集的预测结果与真实值的对比图，从图中可以较为显著的看出神经网络模型的预测值更加接近真实值；为了更加直观的看出两种模型的优劣势，本文选择了统计学中常用的平均绝对误差（MAE）和平均绝对误差百分比（MAPE），多元回归模型输出的结果分别是 MAE 为 10.39，MAPE 为 45.47%；BP 神经网络模型的结果是 MAE 为 7.06，MAPE 为 27.11%，无论是平均绝对误差还是平均绝对误差百分比，这两个指标反映出来的结果均是 BP 神经网络模型对二手书的价格预测效果要优于回归模型。

5.2 相关建议

综合上述研究结论，可以分别对微观的个人卖家、二手书平台和宏观的二

手书市场的营销策略给出如下建议：

(1) 个人卖家

作为二手书卖家，在进行线上二手书的出售过程中可以结合本文中所列出的部分二手书价格特征进行价格筛选，通过多平台价格比较，判断市场对此类书籍的供需状况，最后可以结合本文给出的二手书价格预测模型对自己手里的二手书进行预定价，这比传统的经验定价所带来的期望效益更大。

(2) 在线二手书平台

对于二手书平台来说，本文的研究为平台的二手书定价机制提供了理论支持。相较于现在的大部分二手书平台仅根据二手书单一的特征就给出二手书售价的弊端，本文通过线上二手书平台的数据，构建灰色关联模型筛选出 8 个参考特征：品相、装帧、开本、页数、出版时间、版次、所属学科门类以及二手书的定价，并通过多元回归模型和 BP 神经网络模型比较研究，筛选出预测效果更好的神经网络模型。平台可以在本文研究的基础上优化自身二手书定价机制，标准化二手书定价全流程，这样既可以规避掉二手书买卖双方因为信息不对称导致的额外损失，也有利于规范二手书市场的乱定价错定价现象，更好的规范二手书销售市场，促进二手书市场的繁荣发展。

(3) 宏观二手书市场

通过本文对在线二手书平台定价机理的研究，我们给出对于宏观二手书市场的营销策略的建议：第一，建立清晰透明的二手书定价机制，减少买卖双方之间的信息差；第二，拓展其他二手耐耗品业务，构建二手潮流文化；第三，开拓海外市场，响应国内国外双循环经济发展趋势，积极布局海外市场；第四，多角度引流，政府出台相应政策鼓励大众积极购买二手书，完成整个二手书生态闭环。

5.3 工作展望

本文以二手书价格为研究对象，收集了孔夫子旧书网平台的在售二手书数据，通过对定性数据以及定量数据的描述性统计和构建灰色关联分析模型确定二手书价格的影响因素，并构建多元回归模型和 BP 神经网络模型对二手书价格进行预测，证明了 BP 神经网络模型对二手书价格预测的效果更优，但是研究仍然存在不足之处，针对这些不足，后续研究工作可以从以下几个方面展开：

(1) 本文的数据来源为孔夫子旧书网的在售二手书数据，平台较为单一，在未来的研究过程中，可以拓展到多个平台的多类型二手书数据，从而进一步拓展我们定价模型的适用范围。

(2) 本文研究中，针对的是受众群体较多的平价二手书，未能考虑二手书的收藏因素，所以对于具有溢价效应的藏书、孤本以及有作者签名的二手书的价格预测误差较大，后续可以针对这类书籍展开相关研究。

(3) 本文研究二手书价格预测模型主要用到的是多元回归模型和 BP 神经网络模型，由于机器学习的蓬勃发展，未来可以尝试用神经网络中的 SVM 算法去弥补 BP 神经网络模型中前向网络所带来的问题，也可以考虑引入其他深度学习算法模型去优化预测结果从而给出更精确的价格预测。

参考文献

- [1] 张阿源.基于国内网络旧书业商业模式的比较研究[J].编辑之友,2019(03):12-16.
- [2] 第十九次全国国民阅读调查结果发布[J].国家图书馆学刊,2022,31(03):38.
- [3] 田杨.需求价格弹性视角下的图书差异化定价策略[J].中国出版,2011(15):37-39.
- [4] 张青.探究多空博弈视角下孔夫子高溢价销售图书的价格形成机制[J].出版参考,2016(09):47-48.
- [5] 苏玲,杨磊,邱俊源.C2C二级市场存在下闭环供应链的定价策略和回收模式选择[J].管理学报,2022,19(04):584-594.
- [6] 张雅云,王丽霞.基于价格与销量非线性关系的季节性商品促销定价模型[J].产业与科技论坛,2015,14(14):60-61.
- [7] 郑君君,付克耀.讨价还价模型在风险投资中的应用研究[J].统计与决策,2005(22):52-54.
- [8] 关大宇.我国商业银行贷款定价的最优化模型设计[J].金融论坛, 2006(03):52-57.
- [9] 杜学美,丁璟好,谢志鸿.在线评论对消费者购买意愿的影响研究[J].管理评论, 2016,28(03).
- [10] 李雅.专业性心理求助双重态度的关系研究[D].郑州:郑州大学,2015.
- [11] 李巧,刘凤军.心理距离对二手商品购买意愿的影响[J].财经论丛,2020(03):96-104.
- [12] 刘永芳,马明娜.内隐和外显态度预测消费者行为的一致性研究[J].心理科学,2009,32(03):563-566.
- [13] 徐若之.建立区域高校二手书市场的构想[J].中国统计,2010(08):53-54.
- [14] 张阿源.基于国内网络旧书业商业模式的比较研究[J].编辑之友,2019(03):12-16.
- [15] 郑青青.网络二手书平台经营现状与创新策略研究[D].苏州:苏州大学,2020.
- [16] 陈彤彤,王玲.循环经济下闲置书籍营销策略分析——以BOOK OFF二手书店为例[J].商业经济,2019(08):58-60+143.
- [17] Mitsutaka Matsumoto. Business frameworks for sustainable society: a case study on reuse industries in Japan [J]. Journal of Cleaner Production,2009,17:1547-1555
- [18] Victoria Pérez-Belis, Marta Braulio-Gonzalo, Pablo Juan, et al. Consumer attitude towards the repair and the second-hand purchase of small household electrical

- and electronic equipment. A Spanish case study [J]. *Journal of Cleaner Production*.2017,158:261–275.
- [19] Chunmin Lang, Ruirui Zhang.Second-hand clothing acquisition: The motivations and barriers to clothing swaps for Chinese consumers [J] .*Sustainable Production and Consumption*. 2019,18:156–164.
- [20] Nuan Luo, Yu Wang, Mingli Zhang, et al. Integrating community and e-commerce to build a trusted online second-hand platform: Based on the perspective of social capital [J] .*Technological Forecasting and Social Change*. 2020,153, art. no. 119913.
- [21] Man Xu, Wansheng Tang, Chi Zhou.Operation strategy under additional service and refurbishing effort in online second-hand market [J] .*Journal of Cleaner Production*. 2021,290, art. no. 125608.
- [22] Linlan Zhang, Lidan Fan, Hongxia Peng,et al. Optimal piracy control and pricing strategies considering quality degradation: The effects of policy instruments [J]. *Electronic Commerce Research and Applications*. 2021,48, art. no. 101072.
- [23] Sofronis K. Clerides. Book value: intertemporal pricing and quality discrimination in the US market for books [J].*International Journal of Industrial Organization*. 2002,20:1385–1408
- [24] Chen N.House Price Prediction Model of Zhaoqing City Based on Correlation Analysis and Multiple Linear Regression Analysis [J] .*Wireless Communications and Mobile Computing* .2022 , art. no. 9590704.
- [25] R. Swarnkar., R. Sawant., H. R and S. P.. Multiple Linear Regression Algorithm-based Car Price Prediction [A]. 2023 Third International Conference on Artificial Intelligence and Smart Energy (ICAIS)[C]. Coimbatore, India, 2023, pp. 675-681.
- [26] M. R. Putri, I. G. P. S. Wijaya, F. P. A. Praja, et al. The Comparison Study of Regression Models (Multiple Linear Regression, Ridge, Lasso, Random Forest, and Polynomial Regression) for House Price Prediction in West Nusa Tenggara [A] . 2023 International Conference on Advancement in Data Science, E-learning and Information System (ICADEIS)[C] . Bali, Indonesia, 2023, pp. 1-6.
- [27] Li. X. Prediction and Analysis of Housing Price Based on the Generalized Linear Regression Model [J]. *Computational Intelligence and Neuroscience*.2022, art. no. 3590224.

- [28] Singh, A., Sharma, A. & Dubey, G. Big data analytics predicting real estate prices [J]. International Journal of System Assurance Engineering and Management, 2020,11:208–219.
- [29] 黄泽宇. 基于多元线性回归模型预测太原市二手房价[J]. 消费导刊,2021,(20): 236-237.
- [30] 荆皓天. 基于BP神经网络的天津市二手房价格预测研究[D]. 天津:天津理工大学,2021.
- [31] S. Han, J. Qu, J. Song, et al. Second-hand Car Price Prediction Based on a Mixed-Weighted Regression Model [A]. 2022 7th International Conference on Big Data Analytics (ICBDA)[C].Guangzhou, China, 2022, pp. 90-95.
- [32] J-Velarde, Celis, Roberto, et al.Web Application with Machine Learning for House Price Prediction [J]. International Journal of Interactive Mobile Technologies. 2023, 17(23): 85-104.
- [33] J. J. Wang. Predicting House Price With a Memristor-Based Artificial Neural Network [J]. IEEE Access, 2018, pp. 16523-16528.
- [34] Liu, R., Ren, H. Housing price forecasting based on least squares support vector regression with particle swarm optimization [J]. Journal of Convergence Information Technology,2011, 6(11): 325–333.
- [35] Wang Heyong , Hong Ming. Residential Hedonic Price Multivariate Linear Regression Model Based on Approximative Normalization [J]. Information Technology Journal, 2013,12: 7427-7434.
- [36] Jiang C., Jiang M., Xu Q., et al.Expectile regression neural network model with applications [J]. Neurocomputing, 2017,247:73-86.
- [37] Tai S.An annealing dynamical learning-based relevance vector regression algorithm for housing price forecasting [J]. Journal of Information and Computational Science, 2011,8 (14):3313-3319.
- [38] Karamanou A. Kalampokis E, Tarabanis K .Linked Open Government Data to Predict and Explain House Prices: The Case of Scottish Statistics Portal [J]. Big Data Research, 2022,30, art. no. 100355.
- [39] Sibindi R, Mwangi R.W., Waititu A.G.A boosting ensemble learning based hybrid light gradient boosting machine and extreme gradient boosting model for predicting house prices [J]. Engineering Reports,2023, 5 (4).
- [40] 丁飞,江铭炎. 基于改进狮群算法和BP神经网络模型的房价预测[J]. 山东大学学报（工学版）,2021,51(4):8-16.

- [41] 李圆圆. 基于BP神经网络的北京市二手房交易价格预测研究[D]. 北京:首都经济贸易大学,2018.
- [42] 张望舒,马立平. 城市二手房价格评估方法研究——基于Lasso-GM-RF组合模型对北京市二手房价格的分析[J]. 价格理论与实践,2020(9):172-175,180.
- [43] 马立平.回归分析[M].北京:机械工业出版社, 2014: 71-76.
- [44] 曹明霞. 灰色关联分析模型及其应用的研究[D]. 江苏:南京航空航天大学,2007:13-16.
- [45] 朱凯, 王正林.精通MATLAB神经网络[M].北京:电子工业出版社, 2010: 193-196
- [46] 黄筱婷. 基于在线监测数据的输电线路覆冰短期预测研究[D].广州:华南理工大学,2013:19.